LAPORAN TEKNIS

KLASIFIKASI KONDISI PAKET DARI FOTO MENGGUNAKAN FOUNDATION MODEL DAN CONVOLUTIONAL NEURAL NETWORK

Diajukan untuk

DATASCAPE 2026 – Data Mining Competition

HIMA Data Science Telkom University

Disusun oleh:

Tim Shortafternoon

PROGRAM STUDI BUSINESS INFORMATION TECHNOLOGY

UNIVERSITAS BINA NUSANTARA (BINUS) @BEKASI

2026

DAFTAR ISI

1. Ringkasan 3

2. Masalah dan Data 4

3. Audit Data 4

4. Pra-pemrosesan Gambar 6

5. Model 7

6. Ensemble dan Hasil Validasi 9

7. Pasca-proses dan Hasil Leaderboard 10

8. Analisis Kesalahan 11

9. Kesimpulan dan Pekerjaan Lanjutan 12

Lampiran: Hyperparameter dan Reproduksi 14

1. Ringkasan

Tabel 1. Ringkasan angka utama

Ukuran	Nilai
Macro-F1 public leaderboard terbaik	0,79411
Macro-F1 ensemble pada *val bersih*	0,9001
Foto test yang memiliki kembaran di data latih	34,4 %
Jumlah model di ensemble + model blend	5 + 1

Kami membangun model yang menebak kondisi paket dari satu foto. Pekerjaan dimulai dengan **audit data** sebelum melatih model apa pun. Audit menemukan ribuan file berekstensi `.jpg` yang sebenarnya WEBP/PNG/AVIF, foto identik dengan label berbeda, foto test yang kembar dengan foto latih, dan artefak augmentasi (rotasi, noise) yang menjadi *jalan pintas* di kelas Aman. Temuan ini menentukan cara membaca gambar, cara mengukur validasi (**val bersih**), dan pasca-proses.

Model inti adalah **embedding beku** dari CLIP ViT-B/16 dan DINOv2 ViT-S/14 dengan classifier MLP, ditambah CLIP *multi-crop* 448 px, dua putaran fine-tune **ConvNeXt-tiny**, dan **EfficientNetV2-S 384 px**. Probabilitasnya digabung dengan rata-rata log-probabilitas berbobot, bias per kelas, dan rata-rata antar foto test yang kembar. Ensemble ini mencapai Macro-F1 0,917 di val penuh dan 0,900 di val bersih.

Temuan utama

1. **Validasi tidak mewakili test.** Ensemble terbaik di validasi hanya 0,77–0,78 di leaderboard, karena distribusi test berbeda dari data latih.
2. **Jumlah tebakan Rusak adalah tuas terbesar.** Semua model terlalu sering menebak Rusak di test. Menggabungkan ensemble dengan EfficientNetV2-S (yang lebih jarang menebak Rusak) memberi skor terbaik **0,79411**.
3. **Kelas Lainnya adalah batas skor.** Test berisi ± 3,5 % foto Lainnya (± 107 foto), tetapi model hanya menebak ± 60, dan sisanya ditebak Aman/Rusak dengan yakin.

2. Masalah dan Data

Tabel 2. Kelas dan jumlah foto latih

Kelas	Definisi	Foto latih	Porsi
Aman	Paket/dus utuh, mulus, layak kirim	8.800	72,0 %
Rusak	Paket/dus penyok, sobek, basah, atau hancur	3.001	24,5 %
Lainnya	Kemasan non-standar: kemasan makanan, kantong plastik, paper bag	423	3,5 %
Total data latih · Test: 3.057 foto tanpa label		**12.224**	100 %

Metrik Macro-F1 merata-ratakan F1 ketiga kelas tanpa bobot, sehingga kelas Lainnya (3,5 % data) bernilai sepertiga skor. Model yang selalu menjawab "Aman" mendapat akurasi 72 % tetapi Macro-F1 hanya ± 0,28. Karena itu seluruh pipeline dirancang untuk menjaga kelas kecil: sampler berbobot, bobot kelas, bias logit per kelas, dan pemilihan model berdasarkan Macro-F1.

Split validasi. 15 % data latih (1.833 foto; Aman 1.320 · Rusak 450 · Lainnya 63) dipisahkan secara *stratified* dengan seed 42. Validasi hanya dipakai untuk memilih epoch, hyperparameter, dan bobot ensemble, tidak pernah untuk melatih bobot model.



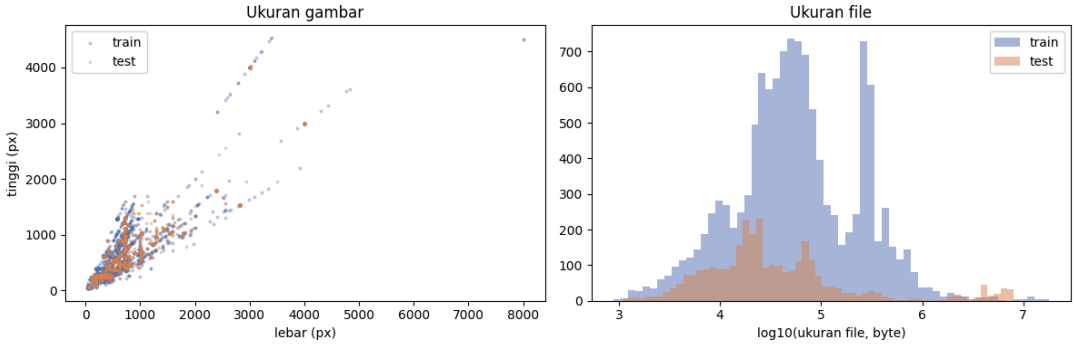
Gambar 1. Contoh foto latih per kelas. Sebagian foto Aman diputar (sudut hitam) atau diberi noise bintik oleh pembuat dataset.

3. Audit Data

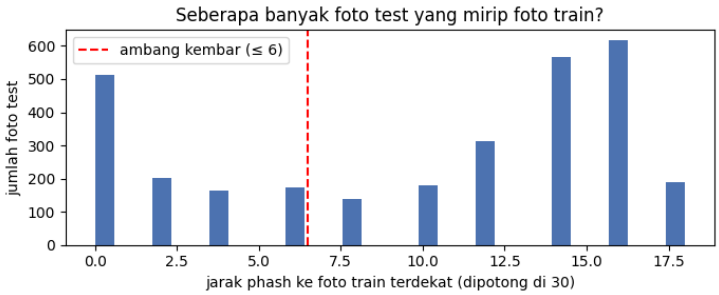
Seluruh 15.281 foto (latih + test) dipindai sekali: **md5** (sidik jari byte), **phash/dhash** (sidik jari visual 64-bit; jarak Hamming ≤ 6 dianggap kembar), format asli, ukuran, dan tiga skor artefak (sudut hitam akibat rotasi, noise *salt-and-pepper*, warna). Dalam pemindaian yang sama, setiap foto disimpan sebagai cache JPEG dengan sisi pendek 448 px.

Tabel 3. Temuan audit data dan keputusan yang diambil

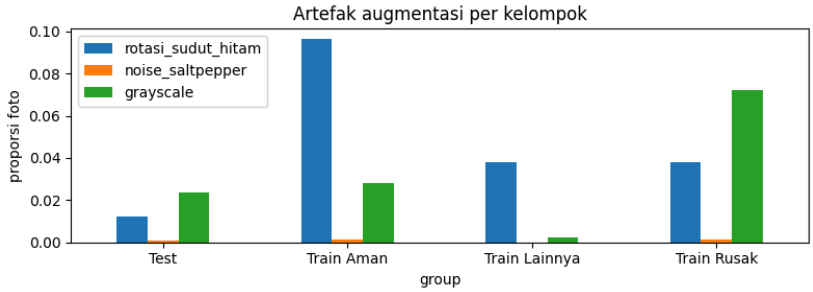
Temuan	Angka	Keputusan
Ekstensi tidak sesuai isi	1.389 file latih dan 615 file test berekstensi `.jpg` tetapi WEBP/PNG/AVIF	Selalu membaca dengan PIL lalu `convert("RGB")`
Duplikat byte-identik di data latih	607 grup, 653 file redundan; **26 grup berlabel konflik** (Aman ↔ Rusak)	Label tidak diubah; label smoothing 0,1
Near-duplicate lintas label	203 pasangan (193 Aman↔Rusak, 10 Aman↔Lainnya); 12.224 foto hanya 9.954 gugus unik	Dicatat sebagai label noise
Kembaran val di data latih	506 dari 1.833 foto val (27,6 %)	Metrik tambahan **val bersih** (1.327 foto)
Kembaran test di data latih	1.053 foto test (34,4 %) berjarak phash ≤ 6; 253 identik byte	Override label **tidak** dipakai
Kembaran di dalam test	366 grup foto test kembar	Prediksi dirata-ratakan per grup
Ukuran & bentuk	Median sisi pendek: Lainnya 155 px, Aman 512 px, Rusak 640 px; 55,7 % foto test tidak persegi	Letterbox, bukan center-crop
Artefak augmentasi	Rotasi (sudut hitam) 9,6 % di train Aman vs 1,2 % di test	Augmentasi noise/rotasi berat dihindari



Gambar 2. Ukuran gambar dan ukuran file, train vs test. Test berisi kelompok yang hampir tidak ada di data latih, misalnya render berukuran sangat besar.



Gambar 3. Jarak phash setiap foto test ke foto latih terdekat. Garis merah adalah ambang kembar (≤ 6): 34,4 % foto test punya kembaran, 2.004 foto benar-benar baru.



Gambar 4. Artefak augmentasi per kelompok. Rotasi paling sering di train Aman tetapi jarang di test: model berisiko belajar "diputar → Aman".

> **Val bersih**
>
> Karena 27,6 % foto val punya kembaran di data latih, model yang sekadar menghafal tampak bagus di val. Setiap model dilaporkan dengan dua angka: **val penuh** (1.833 foto) dan **val bersih** (1.327 foto tanpa kembaran: Aman 1.018 · Rusak 249 · Lainnya 60). Bobot dan bias ensemble dicari di val bersih.

4. Pra-pemrosesan Gambar

- **Pembacaan aman:** `PIL.Image.open(...).convert("RGB")` membaca isi file, bukan ekstensinya. Untuk JPEG besar dipakai `draft()` sehingga decoder langsung menghasilkan versi kecil.
- **Cache 448 px:** foto asli sampai ± 4.000 px diperkecil sekali (sisi pendek 448 px, JPEG kualitas 93). Semua model membaca cache ini, sehingga DataLoader tidak lagi menjadi penghambat.
- **Letterbox:** sisi terpanjang disesuaikan ke ukuran target lalu ditaruh di kanvas abu-abu (124, 116, 104). Rasio aspek tetap dan tidak ada bagian paket yang terpotong.
- **Dataset tahan file rusak:** file yang gagal dibaca diganti sampel acak saat training dan diberi probabilitas seragam 1/3 saat prediksi. Pada data ini tidak ada file yang gagal dibaca.



Gambar 5. Foto asli, letterbox 224 px (dipakai), dan center-crop 224 px (dihindari karena memotong tepi foto).

5. Model

5.1 Embedding foundation model + MLP

Model besar yang dibekukan mengubah setiap foto menjadi vektor: **CLIP ViT-B/16** (OpenCLIP, bobot LAION-2B, 512 dimensi; kuat di semantik, misalnya kardus vs kemasan makanan) dan **DINOv2 ViT-S/14** (384 dimensi; kuat di tekstur dan bentuk). Keduanya dinormalisasi L2 lalu disambung menjadi fitur `base` 896 dimensi. Di atasnya dilatih **MLP** (Dropout 0,1 → Linear 512 → GELU → Dropout 0,3 → Linear 3) dengan StandardScaler, bobot kelas √balanced, label smoothing 0,1, AdamW + OneCycleLR, early stopping, dan rata-rata 3 seed.

5.2 CLIP multi-crop 448 px

Detail kerusakan kecil hilang ketika foto diperkecil ke 224 px. Setiap foto diperbesar/diperkecil ke 448 px lalu dipotong menjadi lima potongan 224 px (empat kuadran + tengah). Embedding CLIP kelima potongan dirata-ratakan dan disambung dengan fitur `base` (1.408 dimensi), lalu dilatih MLP yang sama.

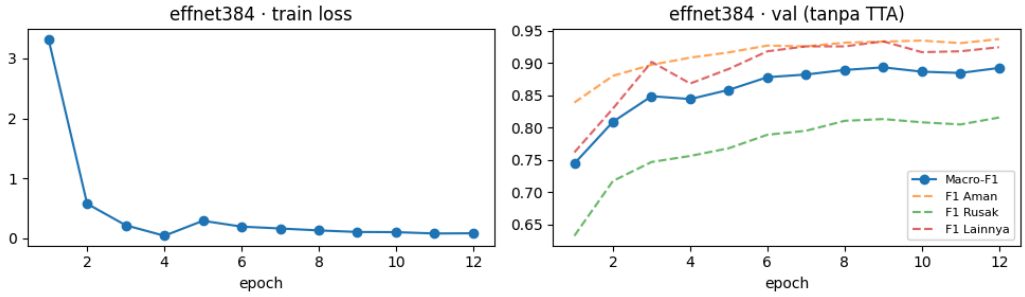
5.3 Fine-tune ConvNeXt-tiny (dua putaran)

Tabel 4. Konfigurasi ConvNeXt-tiny putaran 1 dan 2

Item	Putaran 1	Putaran 2
Resolusi · evaluasi	192 px · resize + center-crop	224 px · letterbox
Lapisan dilatih	stem + 2 stage dibekukan (26,6 juta parameter dilatih)	semua (27,8 juta)
Augmentasi	RandomResizedCrop 0,6–1, jitter 0,3, grayscale 5 %, erasing 15 %	RandomResizedCrop 0,7–1, hflip, jitter ringan (tanpa noise/rotasi)
Sampler	$n^{-0,75}$ per kelas	$n^{-0,5}$ per kelas
Epoch · optimizer	5 / 7 epoch · AdamW (body 1e-4, head 1e-3), warmup 1 epoch + cosine, label smoothing 0,1, mixed precision, TTA hflip	

5.4 EfficientNetV2-S 384 px

Ditambahkan setelah satu EfficientNetV2-S 384 px (notebook tim, dilatih terpisah) bersaing dengan seluruh ensemble di leaderboard. Model `tf_efficientnetv2_s.in21k_ft_in1k` (20,2 juta parameter) dilatih ulang di split kami: letterbox 384 px, hflip, rotasi ±8°, jitter ringan, blur 15 %, dan **noise ringan 15 % ke semua kelas** supaya noise tidak lagi menjadi ciri khas kelas Aman. Training 12 epoch, ± 5 menit per epoch di T4; epoch terbaik ke-9.



Gambar 6. Kurva training EfficientNetV2-S 384 px. F1 Rusak (hijau) tertinggal jauh dari Aman dan Lainnya di sepanjang training.

6. Ensemble dan Hasil Validasi

Skor kelas = rata-rata log-probabilitas berbobot dari setiap model, ditambah bias per kelas $[0, b_{Rusak}, b_{Lainnya}]$. Bobot (0–2 per model) dan bias (langkah 0,25) dicari dengan grid search yang memaksimalkan Macro-F1 di val bersih. Bobot terbaik: MLP multi-crop 2, MLP base 2, ConvNeXt putaran 1 dan 2 masing-masing 1, EfficientNetV2-S 1; bias Rusak +1,00, Lainnya +0,50.

Tabel 5. Macro-F1 setiap model dan ensemble pada data validasi

Model	Val penuh	Val bersih	F1 Aman*	F1 Rusak*	F1 Lainnya*
MLP [CLIP multi-crop + base]	0,8948	0,8770	0,945	0,761	0,926
MLP [CLIP + DINOv2]	0,9027	0,8841	0,944	0,758	0,950
ConvNeXt-tiny putaran 1	0,8789	0,8530	0,926	0,706	0,927
ConvNeXt-tiny putaran 2	0,8761	0,8443	0,930	0,700	0,903
EfficientNetV2-S 384 px	0,8922	0,8665	0,929	0,713	0,957
Ensemble (bobot + bias)	**0,9167**	**0,9001**	**0,942**	**0,784**	**0,974**

* F1 per kelas di val bersih. Bobot dan bias dicari di val bersih, sehingga angka ensemble sedikit optimistis.

Tabel 6. Confusion matrix ensemble pada val penuh

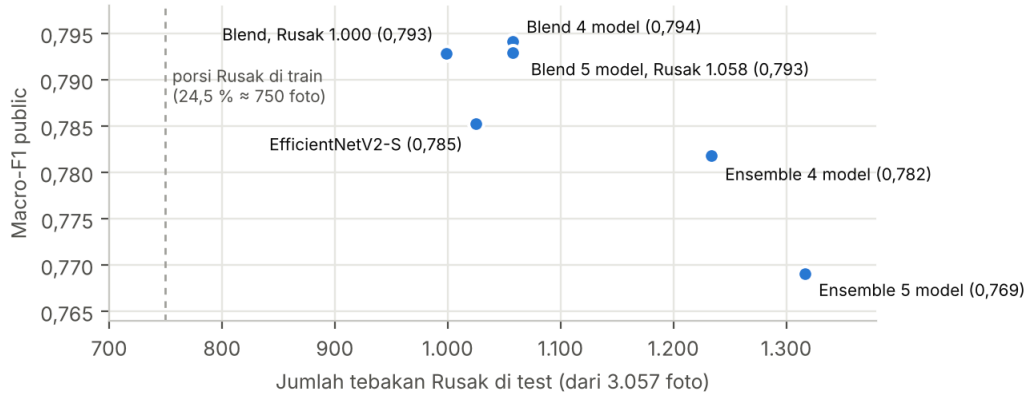
Val penuh: asli ↓ / prediksi →	Aman	Rusak	Lainnya
Aman (1.320)	**1.225**	95	0
Rusak (450)	54	**396**	0
Lainnya (63)	4	0	**59**

Di validasi, kesalahan hampir seluruhnya terjadi antara **Aman dan Rusak**; kelas Lainnya hampir sempurna. Di test, gambaran ini berubah (Bab 8).

Rata-rata foto kembar dan override. Skor test dirata-ratakan di dalam setiap grup foto test yang kembar (366 grup). Foto test yang identik dengan foto latih **tidak** diberi label latih; prediksi model sudah cocok dengan label latih pada 95,1 % dari 468 foto tersebut.

7. Pasca-proses dan Hasil Leaderboard

Ensemble yang optimal di validasi menebak Rusak pada 1.317 dari 3.057 foto test (43 %), padahal porsi Rusak di data latih 24,5 %, dan hanya mendapat 0,76907. Riwayat submission menunjukkan pola yang konsisten: **makin banyak tebakan Rusak, makin rendah skornya**.



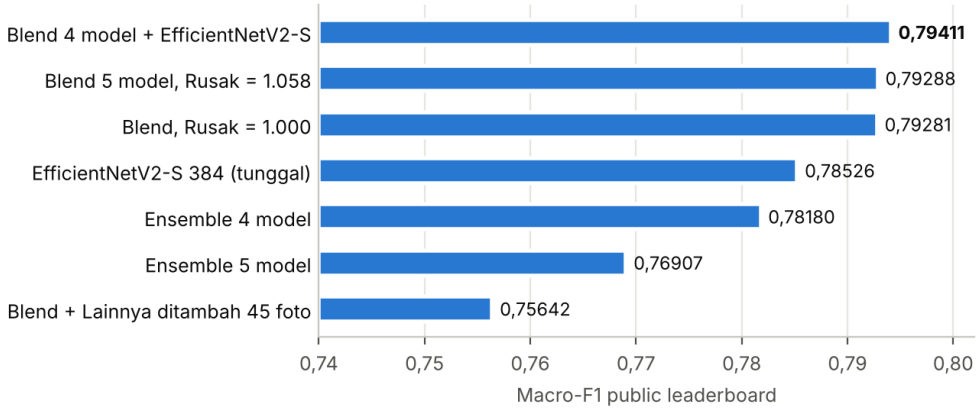
Gambar 7. Jumlah tebakan Rusak vs Macro-F1 public. Titik terbaik berada di sekitar 1.050 tebakan Rusak.

7.1 Blend dengan EfficientNetV2-S

Prediksi EfficientNetV2-S 384 px dari notebook tim hanya tersedia sebagai label, sehingga diubah menjadi probabilitas lunak (0,9 untuk label tersebut, 0,05 untuk kelas lain). Skor gabungan = 0,5 · log-softmax(ensemble) + 0,5 · log(EfficientNetV2-S), lalu dirata-ratakan antar foto test kembar. Dua keluarga model yang salahnya berbeda saling menutupi: blend ensemble 4 model mencapai **0,79411**, di atas masing-masing komponennya (0,78180 dan 0,78526).

7.2 Kalibrasi jumlah Rusak

Bias kelas Rusak dicari dengan *bisection* supaya jumlah tebakan Rusak sama dengan target, sementara jumlah Lainnya dipertahankan. Target 1.058 (sama dengan blend terbaik) memberi 0,79288 untuk ensemble 5 model; target 1.000 pada blend ensemble 4 model memberi 0,79281. Mengurangi Rusak lebih jauh tidak membantu.



Gambar 8. Skor public setiap pendekatan.

Tabel 7. Riwayat submission dan distribusi label test

Submission	Aman	Rusak	Lainnya	Public
Blend ensemble 4 model + EfficientNetV2-S	**1.937**	**1.058**	**62**	**0,79411**
Blend ensemble 5 model, Rusak = 1.058	1.940	1.058	59	0,79288
Blend ensemble 4 model, Rusak = 1.000	1.997	999	61	0,79281
EfficientNetV2-S 384 px saja (notebook tim)	1.970	1.025	62	0,78526
Ensemble 4 model saja	1.764	1.234	59	0,78180
Ensemble 5 model saja	1.681	1.317	59	0,76907
Blend + 45 tebakan Lainnya dari probabilitas model	1.896	1.057	104	0,75642

8. Analisis Kesalahan

8.1 Prediksi per kelompok foto test

Tabel 8. Prediksi per kelompok foto test (A = Aman, R = Rusak, L = Lainnya)

Kelompok	n	Ensemble 5 model	EfficientNetV2-S	Blend	Setuju
Semua	3.057	A1681 / R1317 / L59	A1970 / R1025 / L62	A1854 / R1143 / L60	87,0 %
Identik dengan foto latih	468	A262 / R206 / L0	A282 / R184 / L2	A271 / R195 / L2	93,6 %
Mirip foto latih (phash ≤ 6)	585	A303 / R278 / L4	A390 / R193 / L2	A352 / R231 / L2	81,4 %
Baru (tanpa kembaran)	2.004	A1116 / R833 / L55	A1298 / R648 / L58	A1231 / R717 / L56	87,1 %
Besar (sisi ≥ 1.500 px)	240	A229 / R11 / L0	A234 / R6 / L0	A233 / R7 / L0	97,9 %
Kecil (sisi ≤ 256 px)	663	A554 / R55 / L54	A562 / R46 / L55	A563 / R45 / L55	95,2 %

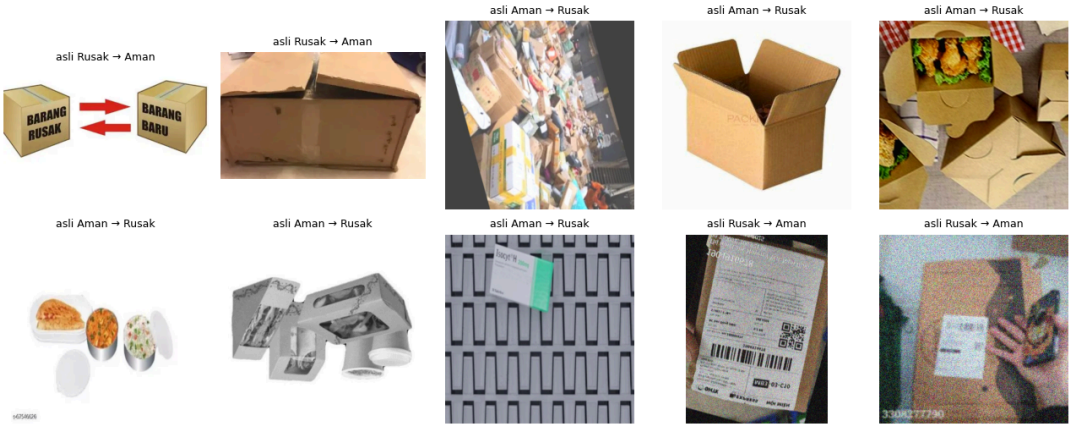
- Perbedaan terbesar antar model ada di foto yang **mirip tetapi tidak identik** dengan foto latih: ensemble menebak Rusak 278 kali, EfficientNetV2-S hanya 193.
- Pada 468 foto yang identik dengan foto latih, model cocok 92–97 % dengan label latih (blend 97,0 %); potensi kenaikan dari override hanya ± 15–20 foto.
- Hampir semua tebakan Lainnya (54–55 dari ± 60) berasal dari **gambar kecil** (≤ 256 px), sama seperti di data latih (median sisi Lainnya 155 px).

8.2 Kelas Lainnya sebagai batas skor

Satu submission berisi satu kelas (semua foto "Lainnya") mendapat 0,02247. Dengan Macro-F1 = (2p / (1 + p)) / 3, porsi Lainnya di test adalah **p ≈ 3,5 % (± 107 foto)**, sama dengan data latih. Model hanya menebak ± 60 foto Lainnya.

Menambah 45 tebakan Lainnya dari foto dengan probabilitas Lainnya tertinggi berikutnya justru menurunkan skor ke 0,75642. Hitungan mundur dari penurunan itu menunjukkan hampir semua tambahan salah, dan dari ± 60 tebakan Lainnya awal hanya sekitar 37–45 yang benar. Artinya ± 60–70 foto Lainnya di test ditebak Aman/Rusak **dengan yakin**. Perkiraan kasar F1 Lainnya di test hanya ± 0,45–0,5, jauh di bawah 0,97 di val bersih.

Skor kemiripan teks CLIP ("kemasan produk" vs "kardus pengiriman") sebagai sinyal tambahan untuk Lainnya hanya mencapai AUC 0,811 di val, sehingga tidak dipakai.



Gambar 9. Contoh foto val bersih yang salah ditebak ensemble. Sebagian kesalahan berasal dari label yang ambigu (misalnya kemasan makanan berlabel Aman, ilustrasi "barang rusak" berlabel Rusak).

9. Kesimpulan dan Pekerjaan Lanjutan

Kesimpulan

1. **Audit data menentukan kualitas evaluasi.** Tanpa val bersih, angka val terinflasi oleh foto kembar (selisih ± 0,02–0,03).
2. **Fitur foundation model + classifier non-linear** adalah komponen terkuat per model di validasi, dan ensemble beragam menaikkan Macro-F1 val bersih dari ± 0,88 ke 0,90.

3. **Distribusi test berbeda.** Bobot dan bias dari validasi mendorong terlalu banyak tebakan Rusak di test. Blend dengan model lain yang lebih konservatif memberi skor terbaik 0,79411.
4. **Batas ± 0,79 berasal dari kelas Lainnya di test**, yang kemungkinan berisi jenis kemasan yang jarang ada di 423 foto Lainnya data latih (misalnya kotak produk ritel yang mirip kardus). Masalah ini tidak bisa diselesaikan dengan menggeser ambang; perlu sinyal atau data baru.

Yang tidak berhasil

- Menambah tebakan Lainnya berdasarkan probabilitas model (0,75642).
- Menambah EfficientNetV2-S 384 px sebagai komponen ensemble tanpa kalibrasi (0,76907).
- Skor teks CLIP untuk mendeteksi kemasan produk (AUC 0,811 di val).

Pekerjaan lanjutan

- Data Lainnya yang lebih beragam (kemasan ritel, kotak produk bermerek, kantong plastik) atau augmentasi yang menyasar kelas ini.
- Membersihkan label konflik (26 grup identik Aman↔Rusak dan 203 pasangan near-duplicate lintas label) sebelum melatih ulang.
- EfficientNetV2-S 384 px dengan 5-fold dan TTA, lalu blend dengan probabilitas (bukan label).
- Validasi yang lebih mirip test, misalnya membobot ulang val berdasarkan kelompok foto yang dominan di test.

Catatan aturan

- Semua bobot pretrained (CLIP, DINOv2, ConvNeXt, EfficientNetV2) adalah bobot publik.
- Label dari foto latih yang identik dengan foto test **tidak** dipakai sebagai jawaban; rata-rata antar foto kembar hanya memakai prediksi model.

Lampiran: Hyperparameter dan Reproduksi

Tabel 9. Hyperparameter setiap komponen

Komponen	Input	Hyperparameter inti
MLP [base]	CLIP B/16 + DINOv2 S/14, 896-d	512 hidden, dropout 0,1/0,3, AdamW lr 1e-3, wd 5e-2, OneCycle, bs 256, maks 60 epoch, patience 12, 3 seed
MLP [multi-crop + base]	1.408-d	sama dengan MLP [base]
ConvNeXt-tiny r1	192 px, crop	5 epoch, bs 48, lr 1e-4/1e-3, wd 0,05, freeze stem + 2 stage, sampler $n^{-0,75}$
ConvNeXt-tiny r2	224 px, letterbox	7 epoch, bs 48, lr 1e-4/1e-3, wd 0,05, semua layer, sampler $n^{-0,5}$
EfficientNetV2-S	384 px, letterbox	12 epoch, bs 16, lr 5e-5/5e-4, wd 1e-4, grad clip 1,0, drop_path 0,1, sampler $n^{-0,5}$
Ensemble	log-prob 5 model	bobot 0–2, bias Rusak −2..1,5 dan Lainnya −2..2 (langkah 0,25), dicari di val bersih
Blend + kalibrasi	ensemble + label EfficientNetV2-S	50:50 log-skor, rata-rata foto kembar, target Rusak 1.058

Reproduksi. Jalankan `DATASCAPE2026_Package_QC_Final.ipynb` di Google Colab dengan GPU (*Runtime → Run all*). Data diunduh otomatis dari Hugging Face; hasil disimpan di `MyDrive/package-qc/` dan sesi yang terputus dapat dilanjutkan. Bagian §11 membutuhkan file prediksi EfficientNetV2-S dari notebook tim dan menghasilkan `submission_final.csv` (versi 0,79288). Untuk mereproduksi 0,79411: hapus `"effnet384"` dari `ENSEMBLE_RUNS`, jalankan ulang §9, lalu set `TARGET_RUSAK = None` di §11.

Waktu komputasi (T4, terukur di run terakhir): unduh data dari Hugging Face ± 44 menit (tanpa token), pembuatan ulang cache ± 3 menit, training EfficientNetV2-S 384 px ± 53 menit (12 epoch).